



IMAGING IPERSPETTRALE PER IL RILEVAMENTO INTRAOPERATORIO DEI TUMORI CEREBRALI

DAI BENCHMARK ALLA PREDIZIONE

Candidato: **Alessandro Botta**

Tutor: Prof. **Giosuè Lo Bosco**

A.A. 2025/2026






Table of Contents

1 Introduzione

- ▶ Introduzione
- ▶ Metodologia e Dati
- ▶ Strategie Avanzate
- ▶ Conclusioni
- ▶ Riferimenti Bibliografici



Il Problema Clinico

Sfide nella Neurochirurgia Oncologica

- **Obiettivo:** Massima resezione del tumore cerebrale preservando le funzioni neurologiche (non si deve asportare tessuto sano) ed evitando emorragie (non si devono toccare vene).




Figure: Esempio di immagine cerebrale: a sinistra, immagine RGB con zona tumorale cerchiata; a destra, segmentazione del cervello in (**NT**= Tessuto Sano, **TT**=Tumore, **BV**=Vasi Sanguigni, **BG**=Background).

Il Problema Clinico

Sfide nella Neurochirurgia Oncologica

- **Obiettivo:** Massima resezione del tumore cerebrale preservando le funzioni neurologiche (non si deve asportare tessuto sano) ed evitando emorragie (non si devono toccare vene).
- **Criticità:** Confini sfumati. Le cellule tumorali si mescolano ai tessuti sani, risultando visivamente indistinguibili.




Figure: Esempio di immagine cerebrale: a sinistra, immagine RGB con zona tumorale cerchiata; a destra, segmentazione del cervello in (NT= Tessuto Sano, TT=Tumore, BV=Vasi Sanguigni, BG=Background).



La Soluzione: Hyperspectral Imaging (HSI)

Dalla visione RGB alla "Biopsia Ottica"

Il Voxel Iperspettrale

A differenza dei sensori RGB (3 bande), l'HSI cattura centinaia di bande spettrali contigue. L'unità minima diventa il **voxel**, generando un Ipercubo 3D (x, y, λ).

La Firma Spettrale:

- Agisce come un descrittore biochimico del tessuto (ossigenazione, emoglobina).
- Permette una classificazione *non-contact*.
- Sfrutta le alterazioni metaboliche del tumore per mapparne i margini.




Figure: Pixel RGB vs Voxel HSI



Table of Contents

2 Metodologia e Dati

- ▶ Introduzione
- ▶ Metodologia e Dati
- ▶ Strategie Avanzate
- ▶ Conclusioni
- ▶ Riferimenti Bibliografici



Il Dataset InVivoBench

Caratteristiche e Criticità

Contesto: Dati *in-vivo* acquisiti durante interventi neurochirurgici reali (Progetto HELICoiD). 61 immagini da 34 pazienti.

Il Problema del Class Imbalance

Il dataset presenta un grave sbilanciamento delle classi. Il Tessuto Tumorale (TT) rappresenta una minima frazione del volume totale.

Classe	Conteggio Voxel	Percentuale
Unlabeled	11.805.660	92,89%
Background (BG)	445.540	3,51%
Normal Tissue (NT)	308.328	2,43%
Blood Vessel (BV)	112.407	0,88%
Tumor Tissue (TT)	37.399	0,29%



Validazione e Prevenzione del Data Leakage

5-Fold Cross-Validation Custom a Livello Paziente

- **Rischio:** Split casuale a livello di voxel causa *Data Leakage*, poiché voxel dello stesso paziente sono fortemente correlati.
- **La Soluzione (Patient-Level Split):**
 - Partizione basata sugli ID univoci dei pazienti.
 - Divisione interna **60% Training / 20% Validation / 20% Test** per ogni fold.
- **Significato Clinico:** Rispecchia lo scenario chirurgico ideale, dove si deve operare un *nuovo* soggetto mai visto in fase di training.




Figure: Schema della rotazione per paziente. Il set di Test isola sempre un paziente mai visto prima.



Analisi delle performance

Il Problema della Sensitività




Figure: Dettaglio Sensitività e Specificità per classe

- **Specificità Ottimale:** Tutti i modelli mostrano un'ottima capacità di rigettare i falsi positivi (Specificità globale > 80-90%).
- La **Sensitività** nella classe Tumor Tissue (TT) è il punto debole strutturale di tutti i classificatori.
- **Falsi Negativi:** I modelli faticano a identificare correttamente *tutti* i voxel tumorali, classificandoli erroneamente come vasi (BV) o tessuto sano (NT).

Analisi Diagnostica dell'Errore

Il fenomeno dell'Ambiguità Spettrale

- Perché i classificatori falliscono sul tumore? L'analisi dei Falsi Negativi tumorali rivela che i voxel misclassificati **non** esibiscono un segnale rumoroso o degradato.
- Le firme spettrali dei voxel errati mimano perfettamente la classe in cui vengono confusi.
- *Esempio:* Un tumore ipervascolarizzato è spettralmente quasi indistinguibile da un vaso sanguigno (BV).

Analisi Spettrale Errori Falsi Negativi (FN) per SVM-L




Figure: Spettri dei Falsi Negativi (SVM)

Analisi Diagnostica dell'Errore

Confronto Visivo: Ambiguità Spettrale

Analisi Spettrale Errori Falsi Negativi (FN) per SVM-L

Analisi Statistica delle Firme Spettrali (Mediana e IQR)




Figure: Firme Spettrali Reali (Ground Truth)




Figure: Firme dei Falsi Negativi (Errori del Modello)



Table of Contents

3 Strategie Avanzate

- ▶ Introduzione
- ▶ Metodologia e Dati
- ▶ Strategie Avanzate
- ▶ Conclusioni
- ▶ Riferimenti Bibliografici

Introduzione all'Ensemble Learning

Dalle predizioni singole all'intelligenza collettiva





Figure: Le probabilità estratte dai 6 classificatori base diventano l'input per un motore di fusione (Ensemble), incaricato di generare la decisione clinica e quantificare l'incertezza.



Risultati degli Ensemble

Trade-off tra Accuratezza e Sicurezza

Analisi Dettagliata: Modelli Singoli vs Strategie Ensemble



- **Soft Voting:** Miglior bilanciamento globale (Macro F1: 0.71).
- **Clinical Stacking / Hierarchical:** Sacrificano la specificità (più falsi positivi) ma **massimizzano la sensibilità** su Tumore e Vasi Sanguigni.

Il ruolo dell'Incertezza Epistemica

Dalla predizione alla valutazione dell'affidabilità




Figure: Sfruttando la divergenza tra i modelli base, l'Ensemble non fornisce solo una classe rigida, ma estrae una **mappa di incertezza** per guidare e supportare le scelte chirurgiche critiche.



Analisi dell'Incertezza Epistemica

Quantificare l'affidabilità della predizione

L'ensemble probabilistico permette di scomporre l'incertezza per isolare il **disaccordo tra i modelli**:

- **Totale** (U_{tot}): Entropia dell'ensemble.

$$U_{tot} = - \sum \bar{p}_c \log_K(\bar{p}_c)$$

- **Media** (U_{ale}): Rumore dei dati.

$$U_{ale} = \frac{1}{M} \sum H(P_m)$$

- **Epistemica** (U_{epi}): Disaccordo.

$$U_{epi} = U_{tot} - U_{ale}; U_{epi} \in [-1, 1]$$

Impatto clinico (r_{pb}): La correlazione statistica globale è **bassa** (≈ 0.20), tuttavia..




Figure: Mappe di Incertezza (Paziente 020-01)



Validazione Operativa

Curve di Risk-Rejection

Cosa succede se il sistema si astiene dal classificare i voxel più incerti, delegandoli al chirurgo?




Figure: Risk-Rejection (Soft Voting)

- Scartando i top 10% **voxel** con Incertezza Epistemica più alta, la **sensitività tumorale** (linea rossa) aumenta di 4 punti, passando dal 63% al 67%.
- L'Ensemble con Soft Voting si avvicina così ai tassi di **sensitività tumorale raggiunti dal Clinical Stacker**, pur mantenendo la più alta specificità tumorale ($\sim 90\%$).



Table of Contents

4 Conclusioni

- ▶ Introduzione
- ▶ Metodologia e Dati
- ▶ Strategie Avanzate
- ▶ Conclusioni
- ▶ Riferimenti Bibliografici



Conclusioni e Sviluppi Futuri

4 Conclusioni

Sintesi dei Risultati

L'HSI è una tecnologia promettente, tuttavia la classificazione voxel-wise soffre di ambiguità intrinseche nel dataset studiato.

Le architetture Ensemble, abbinate all'analisi dell'Incertezza, offrono una soluzione robusta e clinicamente interpretabile dal chirurgo.

Direzioni Future:

- Etichettare i cubi HSI in modo più robusto, validando ad esempio le label con una MRI intraoperatoria.
- Sviluppo di interfacce *Human-in-the-loop* per visualizzare le mappe di rischio durante l'intervento.



Table of Contents





5 Riferimenti Bibliografici

- ▶ Introduzione
- ▶ Metodologia e Dati
- ▶ Strategie Avanzate
- ▶ Conclusioni
- ▶ Riferimenti Bibliografici



Riferimenti Bibliografici

Sviluppo Modelli: Machine Learning e Deep Learning




- C. M. Bishop (2006). *Pattern Recognition and Machine Learning*. Springer.
- M. Berthold, D. J. Hand (2003). *Intelligent Data Analysis: An Introduction*. Springer.
- N. Cristianini, J. Shawe-Taylor (2000). *An Introduction to Support Vector Machines and Other Kernel-based Learning Methods*. Cambridge University Press.
- I. Goodfellow, Y. Bengio, A. Courville (2016). *Deep Learning*. MIT Press.



Riferimenti Bibliografici

Incertezza Epistemica e Validazione Statistica



- **E. Hüllermeier, W. Waegeman (2021).** *Aleatoric and epistemic uncertainty in machine learning: an introduction to concepts and methods*. Machine Learning, 110(3), 457-506.
- **D. J. Sheskin (2011).** *Handbook of Parametric and Nonparametric Statistical Procedures* (5th ed.). Chapman and Hall/CRC.



Grazie per l'attenzione