

IMAGING IPERSPETTRALE PER IL RILEVAMENTO INTRAOPERATORIO DEI TUMORI CEREBRALI: DAI BENCHMARK ALLA PREDIZIONE

Autore: Alessandro Botta *Università degli studi di Palermo*

Tutor: Prof. Giosuè Lo Bosco *Università degli studi di Palermo*

ABSTRACT: L'accurata delineazione dei margini tumorali durante la neurochirurgia è necessaria per la sopravvivenza del paziente. Gli attuali strumenti di guida intraoperatoria, come la neuronavigazione basata su MRI pre-operatoria o la chirurgia guidata da fluorescenza (5-ALA), presentano limitazioni dovute a fenomeni di *brain shift* e all'interpretazione soggettiva. In questo scenario, l'*Hyperspectral Imaging* (HSI) emerge come paradigma alternativo: una tecnologia real-time capace di discriminare i tessuti analizzandone la firma spettrale, ben oltre lo spettro visibile.

Questo lavoro presenta uno studio approfondito sull'impiego di algoritmi di *Machine Learning* (ML) e *Deep Learning* (DL) per la segmentazione tumorale su immagini HSI. La ricerca inizia con la replica e la validazione del benchmark "InVivoBench" (basato sul progetto HELICoID), implementando e confrontando classificatori come *Support Vector Machines* (SVM) (Cristianini and Shawe-Taylor, 2000), *Random Forests* (RF) e *Deep Neural Networks* 1D (1D-DNN) (Goodfellow et al., 2016) su immagini iperspettrali *in-vivo*. Partendo da questa *baseline*, lo studio analizza i limiti degli approcci attuali, affrontando specificamente il problema del *label noise* che affligge intrinsecamente la *ground truth* istologica.

Il lavoro introduce e valuta strategie di aggregazione avanzate (*Ensemble Learning*), implementando meccanismi di *Soft Voting* e un inedito *Clinical Stacking*. I risultati empirici dimostrano che l'aggregazione dei modelli mitiga la varianza, superando in robustezza i singoli classificatori. Centrale, in questo contesto, è l'analisi dell'Incertezza Epistemica. Attraverso l'uso di curve *Risk-Rejection*, dimostriamo che filtrare i voxel ad alta entropia permette di modulare la sensibilità del sistema. L'esito è un approccio *risk-aware*: un sistema di supporto decisionale per il chirurgo che non solo classifica, ma quantifica l'affidabilità della predizione, aprendo la strada a una chirurgia assistita trasparente e computazionalmente robusta.

DICHIARAZIONE DI ORIGINALITÀ: Il presente elaborato costituisce una rielaborazione indipendente e critica del benchmark InVivoBench. Il contributo originale risiede nella progettazione di un'architettura di *Clinical Stacking Ensemble*, specificamente ottimizzata per massimizzare la sensibilità oncologica. Parallelamente, si formalizza una metodologia di validazione basata sull'incertezza epistemica (*Risk-Rejection Curves*), sviluppata per intercettare e abbattere gli errori di classificazione nei contesti clinici *safety-critical*. Il codice volto alla replica dei risultati di (Fabelo et al., 2019), oltre al testing di esperimenti inediti, è scaricabile nella repository GitHub ufficiale del progetto (Botta, 2026).

1 INTRODUZIONE

1.1 Contesto Clinico e Definizione del Problema

Nell'ambito delle patologie oncologiche del sistema nervoso, i gliomi costituiscono la classe di tumori primari più diffusa. Il Glioblastoma (GBM), in particolare, rappresenta la variante più critica a causa della sua rapida evoluzione e della tendenza a espandersi oltre i confini visibili della massa principale. L'attuale protocollo d'intervento punta alla massima rimozione del volume tumorale: i dati confermano infatti che l'entità della massa asportata è il fattore che incide maggiormente sulla durata della vita del paziente e sulla stabilità della sua condizione.

Il problema principale per chi opera riguarda l'incertezza nella classificazione dei tessuti ai margini della lesione. In questa zona di transizione, le cellule tumorali si mescolano a quelle sane in modo tale che, con la normale illuminazione ottica, i due tessuti risultano visivamente indistinguibili. Si genera quindi una necessità di bilanciamento: un'eccessiva rimozione può causare danni permanenti alle funzioni motorie o cognitive, mentre una rimozione insufficiente lascia residui cellulari che portano inevitabilmente a una rapida recidiva (ricomparsa del tumore).

Dal punto di vista tecnologico, gli strumenti di supporto attuali mostrano vulnerabilità strutturali. La neuronavigazione si basa sull'elaborazione di immagini di Risonanza Magnetica (MRI) acquisite prima dell'operazione. Tuttavia, una volta iniziata la procedura chirurgica, il cervello subisce una deformazione fisica dovuta alla gravità e alla variazione di pressione interna. Questo fenomeno di *brain shift* introduce un errore di registrazione tra il

dataset pre-operatorio e la posizione reale dei tessuti (Fabelo et al., 2019), rendendo le mappe digitali geometricamente inaccurate. Altre soluzioni, come l'ecografia, presentano un rapporto segnale-rumore spesso troppo basso, mentre le tecniche basate sulla fluorescenza non garantiscono una rilevazione affidabile in tutti gli scenari operativi.




Figura 1: Confronto tra la struttura di un pixel RGB standard (campionamento discreto) e un voxel iperspettrale (campionamento continuo a 128 bande) nel range VNIR.

1.2 Hyperspectral Imaging (HSI) come Soluzione

L'*Hyperspectral Imaging* (HSI) si presenta come un'evoluzione dei sistemi di visione artificiale, capace di superare la compressione informativa tipica dei sensori RGB. Come illustrato nella Figura 1, mentre un pixel tradizionale campiona il segnale luminoso in tre sole componenti discrete, un sistema HSI acquisisce dati attraverso centinaia di bande spettrali strette e contigue. In questo scenario, l'unità minima di informazione non è più un semplice pixel, ma un **voxel iperspettrale**: un elemento volumetrico che associa a ogni coordinata spaziale (x, y) un vettore ad alta dimensionalità nel dominio della lunghezza d'onda (λ).

Questa architettura dati genera il cosiddetto "ipercubo", una struttura 3D dove la terza dimensione rappresenta la firma spettrale del tessuto. Dal punto di vista della classificazione computazionale, tale firma non è che un descrittore biochimico del materiale inquadrato. Nel monitoraggio intraoperatorio, il voxel iperspettrale risulta sensibile alle variazioni dei livelli di ossigenazione e alla concentrazione di emoglobina. Poiché il metabolismo tumorale altera drasticamente la risposta spettrale rispetto al parenchima sano, è possibile mappare queste divergenze nel segnale per eseguire una "biopsia ottica". Questo permette una segmentazione automatizzata dei tessuti basata puramente sull'analisi dei dati riflessi, eliminando la necessità di campionamento fisico o contatto diretto.

1.3 Stato dell'Arte e Benchmark

L'evoluzione dei sistemi HSI applicati alla neurochirurgia ha trovato un catalizzatore fondamentale in iniziative europee come il progetto HELICoiD. In ciò, il contributo di León et al. (2023) ha definito un'infrastruttura di test rigorosa attraverso il benchmark "InVivoBench", progettato specificamente per la validazione computazionale di modelli di *Machine Learning* su segnali spettrali acquisiti *in-vivo*. Questo benchmark affronta in modo sistematico le problematiche relative alla variabilità inter-paziente e alla consistenza del segnale post-calibrazione, offrendo un ambiente standardizzato per la valutazione comparativa di architetture quali *Support Vector Machines* (SVM), *Random Forest* (RF) e *Deep Neural Networks* (DNN).

Recentemente, è stato introdotto un benchmark degno di nota che potrebbe ridefinire lo stato dell'arte in questo campo, ovvero il benchmark SLIMBRaIN di Martín-Pérez et al. (2025). L'obiettivo tecnico qui è l'integrazione di flussi di dati eterogenei: la combinazione di immagini RGB ad alta risoluzione con la densità informativa dei dati spettrali. Tale approccio di *data fusion* mira a compensare la risoluzione spaziale talvolta limitata dei sensori iperspettrali, garantendo una segmentazione dei tessuti che sia spazialmente coerente e spettralmente accurata.

SLIMBRaIN non sarà oggetto di studio, tuttavia si evidenzia il suo potenziale per delle future ricerche.

1.4 Contributi della Tesi e Struttura

Il lavoro è strutturato come segue:

- **Replica della Baseline:** Inizialmente si implementano e validano la pipeline di classificazione descritta nel benchmark InVivoBench (León et al., 2023). Si utilizza la catena di pre-processing standardizzata e si valutano le prestazioni di modelli classici di ML (SVM, RF, KNN) e DL (1D-DNN) sulla classificazione di Tessuto Tumorale (TT), Tessuto Sano (Normal), Vasi Sanguigni (BV) e Background (BG).
- **Analisi Critica:** Vengono analizzate le limitazioni dell'approccio baseline, concentrandosi in particolare sul problema del *label noise*, dove la *ground truth* istologica potrebbe non allinearsi perfettamente con la realtà spettrale ai confini del tumore.
- **Metodologie Proposte:** Si esplora l'integrazione di modelli *Ensemble*, combinati con quantificatori di incertezza, per migliorare l'accuratezza della predizione, in particolare la sensibilità di rilevazione della classe tumorale (TT).

2 MATERIALI E METODI

In questo capitolo vengono descritte le sorgenti dei dati, l'architettura dei sensori utilizzati e la pipeline computazionale necessaria per trasformare i segnali grezzi in input validi per i modelli di classificazione.

2.1 Sistemi di Acquisizione

Il dataset di riferimento per questo studio è *InVivoBench*, derivato dalle attività del progetto europeo HELICoiD (León et al., 2023). Questo database rappresenta lo standard attuale per la neurochirurgia iperspettrale, fornendo acquisizioni *in-vivo* etichettate. La generazione di tali dati si basa su due paradigmi tecnologici distinti:

- **Sistemi Push-broom:** Operano tramite scansione lineare, garantendo un'altissima risoluzione spettrale (oltre 800 bande). Sebbene siano i principali contributori di *InVivoBench* per la loro precisione, la necessità di movimento relativo tra sensore e scena introduce latenze e potenziali artefatti cinematici.
- **Sistemi Snapshot:** Progettati per l'integrazione *real-time*, catturano l'intero volume informativo in un'unica esposizione. Tale velocità operativa comporta tuttavia un trade-off, limitando la risoluzione spettrale a circa 16-25 bande.

2.2 Dalla Geometria Spaziale al Dominio Spettrale

Il processo di acquisizione, illustrato sinteticamente in Figura 2, trasforma la risposta ottica del tessuto in una struttura dati complessa. A differenza dei sistemi di computer vision tradizionale (RGB), dove ogni coordinata (x, y) restituisce un pixel discreto a tre canali, l'HSI genera un **Ipercubo** $I(x, y, \lambda)$.

2.2.1 L'unità informativa: dal Pixel al Voxel

L'elemento minimo di questo dataset non è un pixel, ma un **voxel iperspettrale**. Come evidenziato nel confronto tra campionamento RGB e HSI, il voxel rappresenta un volume informativo che estende la risoluzione spaziale nelle profondità del dominio spettrale. Mentre un pixel RGB è una triade di valori isolati, il voxel contiene una firma spettrale continua: un vettore ad alta dimensionalità che descrive l'interazione della luce con la materia per ogni punto della scena.

2.2.2 Firma Spettrale e Discriminazione Biochimica

Dal punto di vista dell'analisi dati, la firma spettrale estratta dal voxel agisce come un descrittore biochimico univoco. Nel range VNIR (400-1000 nm), la forma della curva riflette variabili fisiologiche critiche, quali la saturazione di ossigeno e la densità emoglobinica. Poiché i tessuti tumorali (TT) presentano un metabolismo alterato e una vascolarizzazione caotica rispetto al tessuto sano (NT), le loro risposte spettrali mostrano divergenze statisticamente significative. Il compito dei modelli di *Machine Learning* è proprio quello di mappare queste discrepanze nel segnale per automatizzare la segmentazione dei margini tumorali.




Figura 2: Schema del flusso di acquisizione: dall'illuminazione della scena alla generazione dell'ipercubo e all'estrazione della firma spettrale per ogni coordinata spaziale (adattato da León et al. (2023)).

2.3 Pipeline di Preprocessing e Condizionamento del Dato

Prima di sottoporre i voxel ai classificatori, è necessario un processo di raffinamento del segnale per eliminare i bias strumentali. La pipeline implementata segue un approccio deterministico in quattro stadi:

1. **Calibrazione Radiometrica:** Per attenuare l'interferenza data dalla lampada chirurgica, ogni immagine RI (Raw Image RI) viene espressa attraverso la riflettanza $R \in [0, 1]$ tramite la relazione:

$$R = \frac{RI - DI}{WI - DI} \quad (1)$$

dove WI (White Image) e DI (Dark Image) sono rispettivamente i riferimenti di bianco e buio.

2. **Smoothing e Filtraggio Spettrale:** Per mitigare le oscillazioni ad alta frequenza (*spikes*), si applica una convoluzione 1D a livello di voxel. L'uso di un kernel convolutivo 5×1 permette di regolarizzare la curva mantenendo inalterata la posizione dei picchi di assorbimento.
3. **Pruning e Downsampling delle Bande:** A causa della bassa efficienza del sensore iperspettrale agli estremi del range, vengono rimosse le prime 56 e le ultime 126 bande. L'ipercubo risultante a $\lambda = 645$

viene ulteriormente campionato a 128 canali per ottimizzare la convergenza dei modelli senza perdita di generalizzazione.

4. **Normalizzazione Min-Max:** Infine, ogni vettore spettrale viene normalizzato nell'intervallo $[0, 1]$. Questo passaggio di *feature scaling* garantisce che la varianza dell'illuminazione dovuta alla morfologia irregolare del cervello non influenzi negativamente le prestazioni dei classificatori.

2.4 Analisi Critica del Dataset InVivoBench

In questo studio è stata condotta un'analisi quantitativa e qualitativa approfondita del dataset *InVivoBench*, al fine di comprendere le caratteristiche intrinseche dei dati e le potenziali limitazioni che influenzano le prestazioni dei modelli di *Machine Learning*.

2.5 Protocollo di Acquisizione e Considerazioni Etiche

La raccolta di immagini iperspettrali segue un protocollo sperimentale rigoroso, strutturato per garantire la massima coerenza tra l'evidenza clinica e il segnale digitale. Le fasi operative iniziano con la preparazione chirurgica (craniotomia e durotomia), necessaria per l'esposizione diretta del parenchima cerebrale. Una volta stabilizzato il campo, il sistema HSI viene posizionato per la cattura dei dati nell'area d'interesse. In questa fase, l'impiego di marcatori fisici — specificamente anelli di gomma — risulta fondamentale per l'identificazione spaziale delle *Regions of Interest* (ROI). Il ciclo si conclude con la resezione del tessuto e la successiva analisi istopatologica; quest'ultima fornisce la diagnosi definitiva che funge da **Ground Truth** per l'addestramento dei classificatori.

Tuttavia, l'integrità metodologica dello studio deve confrontarsi con una specifica minaccia alla validità esterna (**Threat to Validity 1 - TTV1**). Il requisito del consenso informato, pur essendo un pilastro etico imprescindibile, agisce come un filtro selettivo sulle casistiche. Tale vincolo potrebbe introdurre un *sampling bias* non trascurabile: l'esclusione sistematica di pazienti pediatrici o di soggetti in stadi tumorali avanzati, le cui capacità cognitive risultano compromesse, limita la rappresentatività del dataset. Dal punto di vista della generalizzazione dei modelli, questo sbilanciamento implica che l'accuratezza dei classificatori potrebbe non riflettere l'eterogeneità clinica dell'intera popolazione affetta da gliomi.

2.5.1 Procedura di Etichettatura e Definizione della Ground Truth

L'etichettatura dei dati (Labeling) è stata effettuata mediante un approccio semi-automatico supervisionato da neurochirurghi esperti. Il processo utilizza l'algoritmo *Spectral Angle Mapper* (SAM) per selezionare voxel spettralmente simili a un voxel di riferimento scelto dal medico, entro una certa soglia di tolleranza.

Questo approccio presenta due criticità metodologiche significative:

1. **Assenza di margini netti:** Come evidenziato in Figura 3, le mappe di *Ground Truth* (GT) risultano sparse e non definiscono contorni tumorali continui. Ciò rende il benchmark poco adatto per valutare la completezza della resezione chirurgica, limitando l'analisi a una classificazione *pixel-wise* piuttosto che a una segmentazione semantica completa.
2. **Bias di Augmentation (TTV2):** L'uso dell'algoritmo SAM per espandere il set di etichette tende a selezionare voxel con elevata similarità spettrale, agendo come un filtro che potrebbe escludere firme spettrali tumorali "anomale" o eterogenee. Questo riduce la varianza intra-classe nel training set, semplificando artificialmente il problema di classificazione rispetto alla realtà clinica.

2.5.2 Analisi Esplorativa e Caratterizzazione Statistica dei Dati

L'infrastruttura informativa analizzata si articola in 61 acquisizioni iperspettrali derivanti da molteplici sessioni chirurgiche. L'indagine preliminare sulle proprietà geometriche dei dati, visualizzata nel grafico di Figura 4, rivela un'elevata eterogeneità della risoluzione spaziale. Le dimensioni dei singoli ipercubi oscillano in un range compreso tra circa 300×150 e 750×750 voxel; questa notevole varianza è giustificata dalla volontà di mantenere un'elevato standard qualitativo del dataset, mantenendo esclusivamente le regioni di maggior interesse.

Oltre alla variabilità geometrica, l'analisi evidenzia una criticità strutturale relativa alla distribuzione delle etichette, dettagliata nella Tabella 1. Il dataset manifesta un fenomeno di *Class Imbalance* estremamente marcato. Si osserva innanzitutto una massiccia presenza di dati non annotati: il 92,89% del volume totale dei voxel (oltre 11 milioni di unità) risulta privo di una *Ground Truth* definita. Tra le componenti etichettate, la classe *Background*




Figura 3: Esempio di mappa di Ground Truth. Si noti la natura sparsa delle annotazioni e l'assenza di margini di resezione netti definiti per il tessuto tumorale (TT).




Figura 4: Distribuzione delle dimensioni spaziali (Altezza vs Larghezza) delle 61 immagini iperspettrali del dataset.


(BG) costituisce il cluster predominante, seguita in ordine decrescente dai tessuti sani (NT) e dai vasi sanguigni (BV).

La problematica più rilevante in ottica dei modelli predittivi riguarda la classe *Tumor Tissue* (TT). Nonostante la sua centralità clinica, il tessuto tumorale rappresenta appena lo 0,29% del dataset complessivo. La rarefazione del dato è ulteriormente confermata dalla distribuzione tra le immagini: ben 28 acquisizioni su 61 risultano totalmente prive di voxel appartenenti alla classe TT. Tale asimmetria impone l'adozione di strategie di campionamento specifiche o funzioni di costo pesate per evitare che il modello converga verso predizioni polarizzate sulle classi sovrarappresentate.

Tabella 1: Distribuzione globale dei voxel per classe nel dataset (12.709.334 voxel totali).


ID Label	Classe	Conteggio Voxel	Percentuale (%)
0	Unlabeled	11.805.660	92,89
4	BG (Background)	445.540	3,51
1	NT (Normal Tissue)	308.328	2,43
3	BV (Blood Vessel)	112.407	0,88
2	TT (Tumor Tissue)	37.399	0,29

Analisi Statistica delle Firme Spettrali (Mediana e IQR)



(a) Caratterizzazione statistica (Mediana e IQR) delle firme spettrali.

Analisi Spettrale Errori Falsi Negativi (FN) per SVM-L



(b) Analisi spettrale dei Falsi Negativi (FN) generati dalla SVM-L.

Figura 5: Confronto tra firme globali e pattern di errore: l'evidenza dell'ambiguità spettrale.

2.5.3 Caratterizzazione Spettrale e Analisi delle Ambiguità

L'indagine sulla densità spettrale e sulla relativa varianza interquartile (IQR), sintetizzata nella Figura 5a, consente di mappare i confini biochimici dei tessuti osservati. Sebbene si riscontrino pattern morfologici ricorrenti — legati principalmente ai minimi di assorbimento dell'emoglobina — la pura separabilità delle classi nello spazio delle feature rimane un obiettivo complesso.

Per approfondire tale criticità, è stata condotta un'analisi diagnostica preliminare utilizzando un classificatore a vettori di supporto (**Linear SVM**). L'obiettivo non risiedeva nella performance assoluta, quanto nell'identificazione dei fallimenti sistematici del modello. L'evidenza empirica, illustrata in Figura 5b, ha rivelato un dato inaspettato: i voxel tumorali (TT) classificati erroneamente come Vasi Sanguigni (BV) o Tessuto Normale (NT) non mostrano un segnale degradato o incerto. Al contrario, essi esibiscono profili spettrali che ricalcano fedelmente la firma della classe predetta.

Sotto il profilo del *Pattern Recognition* (Bishop, 2006), questo fenomeno indica una **ambiguità spettrale intrinseca**. Non si tratta di una semplice incapacità di generalizzazione del classificatore, quanto di una sovrapposizione stocastica delle firme. Ad esempio, un tumore ipervascolarizzato produce una risposta di riflettanza che mima perfettamente lo spettro di un vaso sanguigno, rendendo le due classi indistinguibili su base puramente puntuale.

3 Replica e Comparazione dei Classificatori

3.1 Validazione e Prevenzione del Data Leakage

La valutazione delle performance dei classificatori segue un protocollo di validazione rigoroso, progettato per testare la capacità di generalizzazione dei modelli su soggetti mai visti in fase di addestramento. A tale scopo, è stata implementata una procedura di **5-fold Cross-Validation custom**, operante esclusivamente a livello di paziente (*Patient-level split*).

A differenza della k -fold classica, che opera una partizione arbitraria del dataset globale, la logica implementata garantisce l'isolamento dei dati basandosi sugli identificativi univoci dei soggetti (*Patient IDs*). Per ogni fold, il pool di pazienti viene suddiviso seguendo una proporzione di 60/20/20 per le fasi di **Training, Validation e Test**. Tale tripla partizione è essenziale: il set di validazione permette l'ottimizzazione degli iperparametri (con una coarse search su F1-score) e il monitoraggio dell'overfitting, mentre il set di test rimane completamente agnostico rispetto al processo di apprendimento.

La scelta di questo approccio non convenzionale è motivata dalla necessità critica di prevenire il **Data Leakage inter-paziente**. In un dataset iperspettrale, i voxel appartenenti allo stesso volume cerebrale condividono una forte correlazione spaziale e biochimica. Uno split casuale a livello di singolo voxel comporterebbe la presenza di segnali dello stesso paziente in entrambi i set di addestramento e test, portando a una sovrastima artificiale dell'accuratezza. Vincolando l'unità atomica dello split al paziente, si simula invece lo scenario clinico reale, in cui il sistema deve operare su un nuovo soggetto di cui non possiede alcuna informazione pregressa. La Figura 6 illustra schematicamente questa rotazione dei pazienti attraverso i cinque cicli di validazione.




Figura 6: Schema della 5-fold cross-validation custom a livello di paziente. La rotazione assicura che ogni soggetto venga utilizzato per il test esattamente una volta, mantenendo la separazione tra i set di training e validazione per ogni iterazione.

3.2 Ottimizzazione del Training Set e Riduzione Dimensionale

Per ridurre la complessità computazionale e gestire l'elevata densità dei dati iperspettrali, è stata adottata una strategia di sottocampionamento volta a ridurre la ridondanza del *training set*.

Il protocollo di riduzione dimensionale, prevede un primo stadio di **Clustering K-means** (Berthold and Hand, 2003) per l'individuazione di 100 centroidi per classe (400 centroidi totali). Per ciascun centroide, sono stati estratti (senza reinserimento) i 10 voxel più affini mediante l'algoritmo **SAM** (*Spectral Angle Mapper*), portando il dataset finale a una dimensione di 4.000 voxel. La logica del SAM risiede nel calcolo della distanza angolare tra i vettori: un angolo nullo implica la perfetta sovrapposizione delle firme, mentre un incremento dell'angolo riflette una divergenza spettrale crescente.

Sotto il profilo delle performance, questa operazione ha permesso di abbattere i tempi di addestramento di circa 48 volte senza compromettere la capacità predittiva del sistema. Risulta particolarmente significativo l'incremento del 20% dell'accuratezza rilevato sulla classe **Tumor Tissue (TT)**: tale evidenza suggerisce che la selezione di voxel altamente rappresentativi agisca come un filtro regolarizzatore, facilitando l'apprendimento di *feature* discriminanti anche in presenza di un forte sbilanciamento iniziale.

3.3 Pipeline di valutazione incrementale

L'architettura di valutazione adottata si articola in una pipeline incrementale a tre stadi, progettato per isolare e quantificare il contributo di ogni componente alla precisione della predizione finale. Questo approccio permette di monitorare l'evoluzione del segnale: dalla classificazione puramente puntuale alla regolarizzazione basata sul contesto spaziale.

I tre livelli di elaborazione, descritti nel dettaglio nelle fasi di test, sono così strutturati:

1. **Classificazione Spettrale (Spectral):** Rappresenta il *baseline* del sistema. Il modello riceve in input l'ipercubo pre-processato di dimensioni $H \times W \times \lambda$. In questa fase, viene coinvolto uno degli 8 modelli di classificazione candidati per generare due output fondamentali: una *ClassMap* ($H \times W$), dove ogni voxel è assegnato a una delle 4 label, e una *probAllImage* ($H \times W \times 4$), che memorizza la distribuzione di probabilità per ogni classe.
2. **Integrazione Spazio-Spettrale (Spatial/Spectral):** In questo secondo stadio, la pipeline introduce una componente di regolarizzazione spaziale per correggere eventuali incoerenze locali. Il sistema combina la mappa delle probabilità (*probAllImage*) con la prima componente principale (*PC1*) dell'ipercubo originale. L'elaborazione prevede l'applicazione di un filtro **KNN-E locale**, operante su una finestra di 14×14 voxel con $k = 40$. Tale filtraggio effettua uno *smoothing* delle probabilità, producendo mappe (*knn.mapProb* e *knn.classMap*) sensibilmente più coerenti sotto il profilo spaziale.
3. **Raffinamento tramite Voto a Maggioranza (Majority Voting):** L'ultimo stadio mira a consolidare la segmentazione finale sfruttando le informazioni derivanti da un processo non supervisionato. La pipeline integra la mappa etichettata dal KNN con una segmentazione in 24 classi ottenuta tramite *Hierarchical K-Means* (HKM), definita *HKMmap*. Viene quindi eseguito un voto a maggioranza (*MV*) per ciascuno dei 24 cluster, stabilizzando i confini dei tessuti e generando l'output definitivo del sistema, la *mv.classMap*.

La struttura completa della pipeline di valutazione è mostrata in Figura 7.

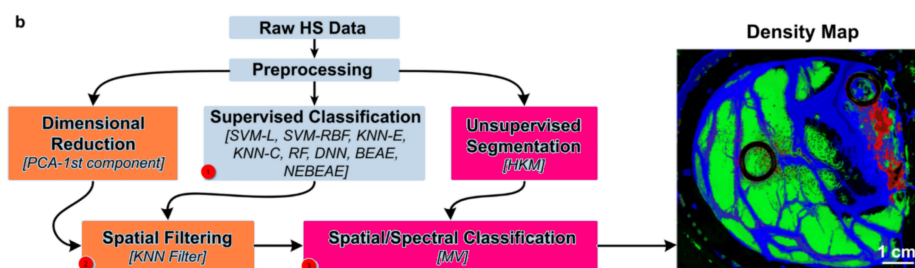


Figura 7: Diagramma a blocchi della pipeline di elaborazione proposta, che integra riduzione dimensionale, classificazione supervisionata e segmentazione non supervisionata.

3.4 Metriche di Valutazione

Per quantificare l'efficacia discriminativa dei modelli e gestire le criticità derivanti dal forte sbilanciamento delle classi, la pipeline di valutazione impiega un set di metriche derivate dalla matrice di confusione. Oltre all'accuratezza globale, è stato necessario adottare parametri capaci di isolare la precisione diagnostica sul tessuto tumorale.

Un vincolo metodologico fondamentale, illustrato in Figura 2, riguarda il calcolo del *Macro F1-Score*: in questa metrica sono state considerate tutte le classi ad eccezione del **Background (BG)**, considerato irrilevante ai fini della segmentazione chirurgica. Inoltre, per garantire la significatività clinica dei test, la valutazione è stata ristretta esclusivamente alle immagini di test contenenti almeno un voxel etichettato come **Tumore (TT)**.

Le metriche utilizzate sono definite dalle seguenti relazioni matematiche:

$$OA = \frac{TP + TN}{TP + TN + FP + FN} \quad ; \quad MacroF1 = \frac{1}{N} \sum_{i=1}^N F1_i \quad (2)$$

$$Sens = \frac{TP}{TP + FN} \quad ; \quad Spec = \frac{TN}{TN + FP} \quad ; \quad F1 = \frac{2TP}{2TP + FP + FN} \quad (3)$$

Dove TP , TN , FP e FN rappresentano rispettivamente i Veri Positivi, Veri Negativi, Falsi Positivi e Falsi Negativi. La *Sensitivity* (o *Recall*) misura la capacità del sistema di identificare correttamente i voxel tumorali, mentre la *Specificity* valuta la precisione nel rigetto del tessuto sano o dei vasi sanguigni. Infine, l'*F1-score* sintetizza il bilanciamento tra precisione e richiamo, fornendo una misura robusta della qualità della segmentazione per ogni singola classe.




Figura 8: Confronto delle distribuzioni del Macro F1-Score per i diversi classificatori. I boxplot mostrano la variabilità delle prestazioni attraverso i 5 fold di validazione.




Figura 9: Analisi dettagliata di Overall Accuracy (OA), Sensività e Specificità per le diverse classi di tessuto. Si noti la criticità nella sensibilità della classe Tumorale (TT).

3.5 Analisi Comparativa delle Performance

I risultati della replica sperimentale, misurati tramite la metrica Macro F1-Score sul test set, sono presentati in Figura 8. L'analisi comparativa con i risultati originali del benchmark evidenzia tre punti chiave:

1. **Coerenza dei Trend:** I modelli basati su Machine Learning (SVM, RF) e Deep Learning (DNN) superano costantemente gli approcci basati su *unmixing* spettrale (EBEAE, NEBEAE), confermando le osservazioni dello studio originale.

2. **Riduzione delle Performance:** Si osserva una sistematica riduzione delle prestazioni (circa il 5%) in tutte le metriche rispetto ai risultati pubblicati. Tuttavia, la varianza tra i diversi fold risulta notevolmente inferiore nella nostra replica, suggerendo una stima più robusta e conservativa dell'errore di generalizzazione.
3. **Impatto del Majority Voting:** Contrariamente alle aspettative, lo stadio di Majority Voting ha mostrato un calo delle prestazioni nel Macro F1-Score. Questo risultato imprevisto potrebbe indicare una sensibilità critica ai parametri di segmentazione non supervisionata o specificità implementative non completamente documentate nel lavoro originale.

Un'analisi dettagliata delle metriche per classe (Figura 9) rivela il tallone d'Achille di tutti i classificatori esaminati: la **Sensitività per il Tessuto Tumorale (TT)**. Mentre la specificità si mantiene su livelli eccellenti ($> 90\%$), indicando un basso tasso di falsi positivi, la capacità di identificare correttamente tutti i pixel tumorali rimane critica, con un alto tasso di falsi negativi. Questo limite, persistente in tutti i modelli, corrobora l'ipotesi di una difficoltà intrinseca nella separabilità delle classi a livello di singolo pixel, probabilmente dovuta alla variabilità biologica e alle limitazioni della ground truth discussa nella sezione precedente.

4 STRATEGIE DI ENSEMBLE E ANALISI DELL'INCERTEZZA

Partendo dai limiti evidenziati nei singoli classificatori (in particolare la bassa sensitività tumorale e l'incapacità di gestire il rischio clinico asimmetrico), questa sezione esplora l'efficacia di strategie di aggregazione avanzate.

Sono stati implementati e confrontati tre approcci di ensemble, ciascuno con una diversa filosofia operativa:

1. **Ensemble Probabilistico (Soft Voting):** Aggregazione basata sulla media ponderata delle probabilità, seguendo la regola della somma (Sum Rule) discussa in (Kittler et al., 1998), ottimizzata per massimizzare le metriche globali.
2. **Hierarchical Risk-Sensitive Thresholding:** Un approccio rule-based progettato per imporre vincoli di sicurezza (Safety) sui vasi sanguigni.
3. **Clinical Stacking (Meta-Learning):** Un approccio data-driven basato sul paradigma della *Stacked Generalization* (Wolpert, 1992), che utilizza una Random Forest per apprendere le correlazioni complesse tra gli errori dei modelli.

4.1 Configurazione degli Esperimenti

4.1.1 Soft Voting Ponderato

Questa strategia costituisce la baseline avanzata. Invece di un semplice voto a maggioranza (*Hard Voting*), che perde l'informazione sulla confidenza, si è calcolata la media pesata delle mappe di probabilità $P_k(x)$ dei sei modelli base ($k = 1 \dots 6$). I pesi w_k sono stati assegnati proporzionalmente al *Macro F1-Score* ottenuto da ciascun modello in validazione. La classe finale è determinata dall'argomento massimo della distribuzione risultante.

4.1.2 Hierarchical Thresholding (Safety-First)

Per affrontare il problema critico dell'emorragia intraoperatoria, è stato sviluppato un modello di decisione a due stadi che riflette il processo decisionale del chirurgo:

- **Safety Layer (BV):** Si identifica una soglia τ_{BV} calibrata per garantire una Recall dei vasi sanguigni (BV) $> 98\%$. Se $P(BV) > \tau_{BV}$, il pixel viene classificato come Vaso, ignorando ogni altra probabilità.
- **Oncological Layer (TT):** Sui pixel residui, si applica una soglia τ_{TT} ottimizzata per massimizzare l'F2-Score, una metrica che pesa la Recall del tumore il doppio rispetto alla Precisione.

4.1.3 Clinical Stacking

È stato addestrato un meta-classificatore *Random Forest* che riceve in input il tensore delle probabilità concatenate dei 6 modelli (6x4 feature per voxel). Per evitare l'overfitting, l'addestramento è stato condotto seguendo le procedure adottate in sottosezione 3.1 per prevenire il data leakage inter-patient. Il modello è stato configurato con pesi di classe fortemente asimmetrici (Tumore: 30, Vasi: 10, Sano: 1) per penalizzare drasticamente i falsi negativi nelle classi critiche.

4.2 Risultati Quantitativi

La Figura 10 mostra il confronto prestazionale tra i modelli singoli e le strategie di ensemble.

L'analisi dei dati rivela un chiaro trade-off tra accuratezza statistica e sicurezza clinica:

- **Soft Voting:** Si conferma la strategia statisticamente più robusta, raggiungendo un **Macro F1 medio di 0.71**, superiore a qualsiasi modello singolo. Questo metodo riesce a mediare efficacemente il rumore delle predizioni individuali, offrendo la migliore segmentazione "generale".
- **Strategie Risk-Sensitive (Thresholding e Stacking):** Questi metodi mostrano un comportamento diverso. Sebbene il loro F1-Score globale sia inferiore (circa 0.64), essi eccellono nelle metriche di sicurezza. In particolare, il *Clinical Stacking* dimostra una capacità superiore di rilevare il tumore infiltrante (Sensitività $TT > 0.70$), mentre il *Thresholding* garantisce una notevole copertura delle strutture vascolari. Il calo dell'F1 è attribuibile a un aumento fisiologico dei Falsi Positivi (riduzione della specificità), che in chirurgia oncologica si potrebbe considerare un "costo accettabile" per evitare residui tumorali.




Figura 10: Confronto finale delle strategie. Il Soft Voting (Verde) offre il miglior bilanciamento globale. Il Clinical Stacking (Arancio) e il Thresholding (Viola) incrementano la sensibilità tumorale e vascolare, accettando un calo nella specificità.

4.3 Analisi e Quantificazione dell'Incertezza

Per valutare l'affidabilità delle predizioni, è stata condotta un'analisi approfondita della calibrazione dell'ensemble. A differenza dei modelli singoli, l'architettura a *Soft Voting* permette di sfruttare la varianza tra i classificatori per decomporre l'incertezza totale in componenti semanticamente distinte, fornendo al chirurgo informazioni più ricche sulla natura del rischio.

4.3.1 Decomposizione dell'Incertezza

Sia x un voxel dell'immagine iperspettrale e $y \in \{NT, TT, BV, BG\}$ la classe target. L'ensemble è composto da $M = 6$ modelli base (RF, SVM-L, SVM-RBF, DNN, KNN-C, KNN-E), ciascuno dei quali fornisce una distribuzione di probabilità $P_m(y|x)$. L'incertezza predittiva totale è stata analizzata attraverso diverse misure:

1. **Incetezza Totale (Total Uncertainty):** Rappresenta l'entropia della distribuzione media dell'ensemble ($\bar{P}(y|x) = \frac{1}{M} \sum P_m$). Misura quanto il sistema è complessivamente "confuso".

$$U_{tot}(x) = H(\bar{P}(y|x)) = - \sum_{c=1}^K \bar{p}_c \log_K(\bar{p}_c) \quad (4)$$

dove $K = 4$ è il numero di classi e il logaritmo in base K normalizza l'entropia in $[0, 1]$.

2. **Incetezza Media (Data Uncertainty):** È la media delle entropie dei singoli modelli. Cattura il rumore intrinseco nei dati (es. confini sfumati, risoluzione spettrale limitata) che rende il campione difficile da classificare per *qualsiasi* modello.

$$U_{ale}(x) = E_m[H(P_m(y|x))] = \frac{1}{M} \sum_{m=1}^M H(P_m(y|x)) \quad (5)$$

3. **Incertezza Epistemica (Model Uncertainty):** Calcolata come la differenza tra l'incertezza totale e quella media (equivalentemente alla *Mutual Information* (Hüllermeier and Waegeman, 2021)). Questa componente misura il **disaccordo** tra i modelli. Se U_{epi} è alta, significa che i modelli sono individualmente sicuri (bassa entropia interna) ma forniscono previsioni divergenti (es. RF predice Tumore, SVM predice Vaso).

$$U_{epi}(x) = U_{tot}(x) - U_{ale}(x) \quad (6)$$

Questa distinzione è clinicamente rilevante: un'alta incertezza media suggerisce un limite fisico del sensore, mentre un'alta incertezza epistemica indica una zona "ambigua" dove i vari modelli non hanno raggiunto un consenso, richiedendo massima attenzione umana.




Figura 11: Analisi dettagliata per il paziente 020-01 ($r_{pb} = 0.72$). Il pannello mostra le tre componenti dell'incertezza e la mappa degli errori (in rosso). Si noti come l'Incertezza Epistemica (in basso a sinistra) isoli con estrema precisione i bordi della lesione dove avviene l'errore, segnalando il disaccordo tra i modelli.

4.3.2 Validazione Statistica: Correlazione Punto-Biseriale

Per dimostrare che queste metriche sono indicatori validi di rischio, è stata calcolata la correlazione statistica tra i valori di incertezza (continui) e l'effettivo errore di classificazione (binario: 0=Corretto, 1=Errore). Lo strumento utilizzato è il coefficiente di **Correlazione Punto-Biseriale** (r_{pb}) (Sheskin, 2011), idoneo per misurare la relazione tra una variabile continua e una dicotomica:

$$r_{pb} = \frac{\mu_{err} - \mu_{corr}}{\sigma_{tot}} \sqrt{\frac{N_{err} \cdot N_{corr}}{N^2}} \quad (7)$$

Dove μ_{err} e μ_{corr} sono le medie dell'incertezza rispettivamente per i pixel errati e corretti. Mentre σ_{tot} è la deviazione standard dell'incertezza in tutti i pixel.

4.3.3 Analisi Quantitativa dei Risultati

L'analisi è stata applicata all'intero dataset di test (Tabella 2). I dati mostrano una tendenza media e mediana della correlazione bassa (rispettivamente 0.203 e 0.278 per l'incertezza epistemica). L'analisi disaggregata rivela dettagli significativi.

Tabella 2: Sintesi dell'analisi di correlazione (r_{pb}) per i casi più significativi. Vengono riportati i valori per l'Incertezza Totale, Media ed Epistemica, seguiti dalle statistiche globali dell'intero dataset.

Categoria	Paziente	Totale (U_{tot})	Media (U_{ale})	Epistemica (U_{epi})
Best Cases	020-01	0.756	0.625	0.778
	034-02	0.587	0.562	0.586
	039-01	0.489	0.460	0.461
	008-02	0.431	0.360	0.546
	036-02	0.485	0.480	0.357
Worst Cases	056-02	-0.614	-0.645	-0.373
	008-01	-0.575	-0.533	-0.520
	053-01	-0.419	-0.411	-0.387
Dataset Mean		0.201	0.182	0.203
Dataset Median		0.260	0.218	0.278

Nei casi di "Best Performance" (es. paziente 020-01, 008-02), si osserva che l'**Incertezza Epistemica** (U_{epi}) mostra spesso una correlazione con l'errore superiore a quella media. Questo suggerisce che, in scenari complessi, l'errore nasce prevalentemente dal disaccordo tra i modelli: l'ensemble sta "dibattendo" su pixel ambigui, e questo dibattito è un predittore d'errore più forte del semplice rumore dei dati.

Al contrario, i "Worst Cases" (es. 056-02, $r_{pb} \approx -0.6$) evidenziano situazioni di *Overconfident Error*: il modello sbaglia con alta sicurezza (bassa entropia). Un'ispezione qualitativa di questi casi potrebbe suggerire la presenza di artefatti sistematici (es. riflessi speculari o ombre nette) che ingannano uniformemente tutti i classificatori, portando a un consenso errato.

La Figura 11 mostra visivamente questo risultato: l'incertezza non è rumore casuale, ma si localizza sui bordi del tumore e dei vasi sanguigni, offrendo una guida visiva "risk-aware" indispensabile per l'operatore.

4.4 Validazione Operativa: Curve di Risk-Rejection

Sebbene l'analisi della correlazione punto-biseriale abbia evidenziato un legame statistico eterogeneo tra incertezza ed errore, la reale utilità clinica del sistema emerge valutando le prestazioni in uno scenario operativo *Human-in-the-loop*.

A tale scopo, sono state generate le **Curve di Risk-Rejection** per le tre strategie di ensemble (Figura 12). Questi grafici illustrano l'evoluzione delle metriche al variare della percentuale di voxel scartati, selezionati in base alla loro Incertezza Epistemica.




Figura 12: **Analisi Comparativa del Risk-Rejection.** (a) Il **Soft Voting** mostra il guadagno maggiore: scartare i dati incerti alza drasticamente la sensibilità tumorale (rossa) mantenendo alta la specificità (arancio). (b) Il **Clinical Stacking** parte da una sensibilità tumorale superiore ma con specificità più bassa, e mostra curve più stabili. (c) L'**Ensemble Gerarchico** presenta le performance globali inferiori e curve piatte, indicando che i vincoli rigidi di sicurezza limitano il beneficio derivante dal filtraggio dell'incertezza.

L'analisi comparativa rivela tre profili di comportamento distinti:

- **Soft Voting (Approccio Conservativo):** È la strategia che beneficia maggiormente dell'incertezza. Parte con una **Specificità eccellente** (≈ 0.89 , linea arancione), indicando una grande precisione nel non rimuovere tessuto sano o vasi sanguigni, tuttavia pecca inizialmente in sensitività. L'applicazione del rejection permette di recuperare i tumori mancati (la linea rossa sale), rendendolo il candidato ideale per interventi in aree dove la preservazione funzionale è prioritaria.
- **Clinical Stacking (Approccio aggressivo):** Mostra un comportamento opposto. Parte con una **Sensitività Tumorale nettamente superiore** (≈ 0.73 contro il 0.63 del Soft Voting) ma paga questo vantaggio con una specificità inferiore (≈ 0.78). La curva più piatta suggerisce che il meta-modello è intrinsecamente robusto: ha già risolto le ambiguità spettrali internamente, rendendo il filtro dell'incertezza meno impattante. È la scelta per la massimizzazione della resezione.
- **Hierarchical Ensemble (Vincolo di sicurezza):** Questo approccio mostra le metriche globali più basse (Macro F1 < 0.65). La sua natura rigida, basata su soglie di sicurezza per i vasi sanguigni ("Safety-First"), impone decisioni forzate che l'incertezza epistemica non riesce a mitigare efficacemente. La staticità delle sue curve conferma che l'imposizione di regole *hard-coded* tende a dominare sull'informazione probabilistica fornita dall'ensemble.

In conclusione, l'incertezza epistemica non è una soluzione universale, ma uno strumento che potenzia specificamente le architetture probabilistiche (Soft Voting), trasformandole da classificatori moderati a sistemi di supporto decisionale altamente affidabili.

5 DISCUSSIONE E CONCLUSIONI

Questo lavoro ha esplorato il potenziale dell'*Hyperspectral Imaging* (HSI) come tecnologia abilitante per la neurochirurgia di precisione, affrontando la sfida critica della segmentazione intraoperatoria dei tumori cerebrali. Partendo dalla replica del benchmark InVivoBench, la ricerca si è evoluta verso lo sviluppo di architetture Ensemble avanzate e l'integrazione di metriche di incertezza predittiva, con l'obiettivo di superare i limiti di affidabilità dei singoli classificatori.

5.1 Sintesi dei Risultati

L'analisi sperimentale ha confermato che, sebbene le firme spettrali contengano informazioni discriminanti, la loro classificazione puntuale è ostacolata da una significativa variabilità biologica e da artefatti di acquisizione. In questo contesto, le strategie di aggregazione proposte hanno dimostrato un chiaro valore aggiunto:

- Il **Soft Voting Ensemble** si è rivelato l'approccio più equilibrato, garantendo un'elevata specificità e beneficiando in modo sostanziale del filtraggio basato sull'incertezza.
- Il **Clinical Stacking** ha offerto una soluzione orientata alla massimizzazione della sensitività tumorale ($\approx 73\%$), dimostrandosi intrinsecamente robusto al disaccordo tra i modelli base, pur al costo di una maggiore incidenza di falsi positivi.

5.2 Il Paradosso dell'Incertezza e la Qualità del Dato

Un risultato centrale di questo studio risiede nell'analisi dell'**Incertezza Epistemica**. Sebbene la correlazione statistica globale tra incertezza ed errore si sia rivelata bassa ($r_{pb} \approx 0.20$), l'analisi operativa tramite le curve di *Risk-Rejection* ha svelato una realtà più complessa. L'incremento della sensitività tumorale ottenuto scartando i voxel più incerti dimostra che il sistema è in grado di "auto-diagnosticare" le proprie lacune nelle aree critiche.

Tuttavia, la persistenza di errori ad alta confidenza (*Overconfidence*) e la difficoltà nel raggiungere una sensitività superiore all'80% suggeriscono una problematica strutturale che trascende l'architettura dei modelli: la **qualità della Ground Truth**. Come discusso in fase di analisi del dataset, l'etichettatura semi-automatica basata su similarità spettrale (SAM) potrebbe aver introdotto un *bias* sistematico, definendo confini netti dove biologicamente esiste un gradiente di infiltrazione. È plausibile ipotizzare che molti dei "Falsi Positivi" o delle zone ad alta incertezza rilevate dai nostri ensemble non siano errori computazionali, ma rispecchino una realtà biochimica che la "verità" istologica, campionata in modo sparso, non riesce a catturare pienamente. L'ambiguità intrinseca di alcune firme spettrali potrebbe quindi non essere un limite del sensore, ma la manifestazione della natura diffusa della patologia.

5.3 Prospettive Future

Alla luce di queste evidenze, le future direzioni di ricerca dovrebbero focalizzarsi non solo sul raffinamento algoritmico, ma sulla ridefinizione del paradigma di validazione:

1. **Miglioramento della Ground Truth:** È imperativo evolvere verso protocolli di annotazione che integrino istologia puntuale densa e imaging multimodale (es. MRI intraoperatoria), per validare la natura dei tessuti nelle zone di incertezza spettrale.
2. **Sistemi Human-in-the-loop:** L'integrazione delle mappe di incertezza nei visori chirurgici rappresenta il passo successivo fondamentale. Trasformare l'output del modello da una semplice maschera n-aria a una mappa che espone il rischio probabilistico permetterebbe al chirurgo di integrare la propria esperienza laddove l'algoritmo segnala ambiguità.

In conclusione, questo studio dimostra che il machine learning applicato all'HSI può diventare uno strumento clinico affidabile, a patto di abbandonare la pretesa di un'automazione cieca in favore di un approccio *risk-aware*, dove la macchina non si limita a classificare, ma dialoga con il chirurgo quantificando la propria incertezza.

Riferimenti bibliografici

- Berthold, M. and Hand, D. J. (2003). *Intelligent Data Analysis: An Introduction*. Springer, Berlin, Heidelberg, 2nd edition.
- Bishop, C. M. (2006). *Pattern Recognition and Machine Learning*. Information Science and Statistics. Springer, New York.
- Botta, A. (2026). HSI-benchmark-eval: Codice sorgente per la segmentazione di tumori cerebrali su immagini iperspettrali. <https://github.com/AliasBotta/HSI-benchmark-eval>.
- Cristianini, N. and Shawe-Taylor, J. (2000). *An Introduction to Support Vector Machines and Other Kernel-based Learning Methods*. Cambridge University Press, Cambridge, UK.
- Fabelo, H., Ortega, S., Szolna, A., Bulters, D., Callicó, G. M., Lazcano, R., Salvador, R., Madroñal, D., Juárez, E., Villa, M., et al. (2019). In vivo hyperspectral human brain image database for brain cancer detection. *IEEE Access*, 7:39098–39116.
- Goodfellow, I., Bengio, Y., and Courville, A. (2016). *Deep Learning*. Adaptive Computation and Machine Learning. MIT Press, Cambridge, MA, USA.
- Hüllermeier, E. and Waegeman, W. (2021). Aleatoric and epistemic uncertainty in machine learning: an introduction to concepts and methods. *Machine Learning*, 110(3):457–506.
- Kittler, J., Hatef, M., Duin, R. P. W., and Matas, J. (1998). On combining classifiers. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 20(3):226–239.
- León, R., Fabelo, H., Ortega, S., Cruz-Guerrero, I. A., Campos-Delgado, D. U., Szolna, A., Piñeiro, J. F., Espino, C., O'Shanahan, A. J., Hernandez, M., et al. (2023). Hyperspectral imaging benchmark based on machine learning for intraoperative brain tumour detection. *npj Precision Oncology*, 7(1):112.
- Martín-Pérez, A., Villa, M., Rosa Olmeda, G., Sancho, J., Vazquez, G., Ortega, S., Fabelo, H., and Callicó, G. M. (2025). Slimbrain database: A multimodal image database of in vivo human brains for tumour detection. *Scientific Data*, 12(1):836.
- Sheskin, D. J. (2011). *Handbook of Parametric and Nonparametric Statistical Procedures*. Chapman and Hall/CRC, Boca Raton, 5th edition.
- Wolpert, D. H. (1992). Stacked generalization. *Neural networks*, 5(2):241–259.